

Data Analytics

Data Integration: ETL/ELT

Prof. Stefan Keller, FS26

Inhaltsüberblick diese VoWo 07

- Informations- und Datenintegration
- Extract-Transfer-Load (ETL) und ELT
- Tools für die Datenintegration

INFORMATION- UND DATEN- INTEGRATION

- Definition DI: Die korrekte, vollständige und effiziente Zusammenführung von Daten und Inhalten verschiedener, heterogener Quellen zu einer einheitlichen und strukturierten Informationsmenge zur effektiven Interpretation durch Anwendungen und Nutzer.
- Informationsintegration → Datenintegration / Data Integration (DI)
- Datenintegration beinhaltet: Datenimport, Datenkonversion, Datenvalidierung, Datenbereinigung, Datentransformation, Datenfusion (conflation, conciliation), Datenaggregation, Datenfilterung, Datenberechnung, (Datenanreicherung, Datenanonymisierung, Datengenerierung), ... (vgl. übernächste Folie)

- "Data Scientists - und Data Engineers - verbringen min. 80 % ihrer Zeit damit, Daten zu finden, die sie analysieren wollen, die Daten zu bereinigen und sie zu integrieren" – In "ML-in-Databases"
- Bis 60% der Zeit eines Datenwissenschaftlers wird mit der Datenbereinigung verbracht – (2019 sagte jemand 95%: "Automating Data Wrangling - The Next Machine Learning Frontier ", Open Data Science)

Informations- und Datenintegration: Ziele

- Datenintegration ist – wie Data Engineering – von grosser Bedeutung
- Es gibt grosse Unterschiede zwischen Data Warehouses und Machine-Learning bei der Zielsetzung etc.:

Aspekt	Data Warehouse (Operations Research)	Machine Learning (Data Science)
Ziel der Integration	Ist-Analyse, Reporting, Historisierung	Schnelle Exploration, Modelltraining
Datenmodellierung	Fixierte, strukturierte Schema-Modellierung	Flexible, agile, explorative Ansätze, Feature-Engineering
Aktualität	Periodisch (batch-orientiert)	Periodisch (batch-orientiert) aber auch Streaming, Near-Realtime möglich
Datenqualität	Fokus auf Konsistenz, historische Genauigkeit	Fokus auf Genauigkeit, Aktualität, Bias, Feature-Qualität
Datenquellen	Primär strukturiert, intern	Divers, oft unstrukturiert, extern/intern
Technologien	Relationale multi-model Datenbanken, ETL-Tools, Konverter, SQL, Python/Pandas	Pipeline Tools, Konverter, SQL, Python/Pandas


- Für fast alle erwähnten Ziele sind Transformations-Funktionen zentral
- Hier alle Funktionen mit SQL-Support, die wir behandeln:
 1. Datenbereinigung: Entfernen von Duplikaten, ungültigen oder fehlenden Werten, etc..
 2. Datentransformation: Schema-Abbildung; Ändern der Struktur von Daten, z.B. Konvertieren von Werten in einen anderen Datentyp, Aufteilen von Spalten, Zusammenführen von Spalten
 3. Datenaggregation Zusammenfassen von Daten aus mehreren Quellen
 4. Datenfilterung: Auswahl von Datensätzen
 5. Datenberechnung: Hinzufügen von berechneten Spalten
 6. Datenanreicherung: Hinzufügen von Daten aus externen Quellen (z.B. Web Scraping; Geocoding)
 7. Datenanonymisierung, Datengenerierung: Generierung synthetischer Daten

Datenintegration: Funktionen (Forts.)


- Hier nicht behandelt, da entweder vorausgesetzt, früher schon behandelt, oder nicht so wichtig (da produktspezifisch):
 - Datenimport, Datenkonversion (Reader/Writer, Formate, Encoding UTF8)
 - Datenvalidierung (z.T. mit SQL-Support)
 - Datenoptimierung (Aggregation, Materialized Views, z.T. mit SQL-Support)
 - Datenmigration (z.T. mit SQL-Support)
 - Datenfluss-Steuerung (Workflows, die Pipelines steuern), Scheduling
 - Data Streaming

sowie Datenvisualisierung (vgl. VoWo 1), etc.

Schematische Darstellung des Datenflusses einer Datenintegration in ein Data Warehouse



Beim Data Lakehouse entfallen bei einigen Daten die ETL-Schritte – ausser "Data Loading«



- Vorgehensweisen:
 - Top-Down: Ausgangspunkt vorgegebenes Zielschema (z.B. durch Standards). Finden der Korrespondenzen zu lokalen Quell-Schemata und Definition der Abbildungen
 - Bottom-Up: Ausgangspunkt existierende Quell-Schemata. Konstruktion eines davon abgeleiteten, integrierten Zielschemata, das möglichst den vollständigen Informationsgehalt aller Quellen enthält
- Typische Aspekte der Heterogenität (Vorlesung Kai-Uwe Sattler 2014):
 - unterschiedliche Repräsentation der Daten
 - unterschiedliche Datentypen
 - unterschiedlicher Umfang der unterstützten Datentypen
 - unterschiedliche interne Darstellung der Daten
 - auch unterschiedliche „Werte“ eines Datentyps zur Repräsentation derselben Information

Datenintegration: Kriterien für Integrationsmethoden und -Prozesse

- Vollständigkeit:
 - Integriertes Schema muss alle Konzepte beinhalten, die in einem lokalen Schema enthalten sind
 - Es darf keine in einem lokalen Schema enthaltene Information verloren gehen
- Minimalität:
 - Real-Welt-Konzepte, die in mehreren lokalen Schemata modelliert sind, dürfen nur einmal im integrierten Schema repräsentiert sein
- Verständlichkeit:
 - Integriertes Schema sollte leicht verständlich sein
- Korrektheit:
 - Alle in dem integrierten Schema enthaltenen Informationen müssen in mindestens einem lokalen Schema semantisch äquivalent vorhanden sein
 - Inter-Schema-Beziehungen, die während der Integration neu hinzugekommen sind, dürfen nicht im Widerspruch zu Informationen aus den lokalen Schemata stehen, d.h. nur konsistente Ergänzungen der bestehenden Schemata sind erlaubt


(Batini et al., 1986)

Datenintegration: Klassifikation von Integrationskonflikten

- Semantische Konflikte:
 - Oft nicht genau die gleiche Menge von Real-Welt-Objekten repräsentiert (z.B. öff. Sitzbänke)
- Beschreibungskonflikte:
 - Unterschiedliche Eigenschaften/Attribute derselben Objekte; Homonyme und Synonyme der Tabellen/Attribute; Datentypkonflikte / Wertebereichskonflikte; unterschiedliche Masseinheiten
- Heterogenitätskonflikte:
 - Unterschiedliche Schemata; unterschiedliche Modellierungskonstrukte und Ausdruckskraft der Modellierungssprachen; impliziert oft auch strukturelle Konflikte
=> Auflösung durch Schema-Transformation
- Strukturelle Konflikte:
 - Unterschiedliche Modellierung (z.T. Vererbung); fehlende Attribute; unterschiedliche Annahmen (Default-Werte), z.B. länderspezifische Höchstgeschwindigkeiten
- Datenkonflikte:
 - Falsche/unkorrekte/veraltete Daten; unterschiedlich codierte Aufzählwert-Werte, unterschiedliche Aufzählwert-Ausdrücke

Datenintegration: Ziel

- Integriertes Schema: Daten aus mehreren unterschiedlichen Quellen:



Referenz: HUB/HPI

Datenintegration: Challenges

- Arten der Heterogenität - unser Fokus hier
- Semantische Heterogenität
 - Begriffe, Objektkonzepte
- Modellierungsheterogenität (Schema, Datenmodell)
 - Datenstrukturen und Datentypen, Regeln und Beschränkungen...
 - Z.B. Objekt/Instanz: Texttyp vs. Datentyp
 - Z.B. Objekt-/Instanz-Sets: zeilenorientiert vs. geschachtelt (JSON)
 - Z.B. unterschiedliche Attributnamen (oder Homonyme)...
- Technisch-strukturelle Heterogenität (Zugriffsart, Codierung)
 - Zugriffsmethoden
 - Datenformate: binär vs. menschenlesbar (CSV, XML, JSON, ...)
 - Kodierung (Little/Big Endian, EOL, UTF8, String Escaping)

Datenintegration: Beispiel

■ Beispiel:

- Vier Mitarbeiter-Datenbanken
- Vier Schemas

■ (IC = Integration Conflict)

mitarbeiter			
p_id	vorname	nachname	funktion
1	Peter	Müller	Sachbearb.
5	Petra	Weger	Sekr.
...	...	...	...

mitarbeiter (leitend)		
p_id	vorname	name
2	Stefanie	Meier
2	Petra	Weger
2	Andreas	Zwickel
...	...	...

Homonym

Fehlendes
(ableitbares)
Attribut

IC Konflikt (Eindeutigkeit)

mitarbeiter			
p_id	Vorname VARCHAR(35)	nachname	alter
1	Wolfgang	Meyer	33
5	Klaus	Schmidt	NULL
...	...	...	...

IC:
alter > 18

Synonym


mitarbeiter			
p_id	Vorname VARCHAR(20)	name	alter
1	Peter	Müller	0
5	Petra	Weger	17
...	...	...	...

Default
Werte

Datentypkonflikt

Referenz: HUB/HPI

Datenintegration - Klassifikation von Datenfehlern




Quelle: Abb. 8.1 Informationsintegration, Leser und Naumann (2006)


- DWH unabhängig von Quellsystemen
 - Problem der Datensynchronisation bei Änderungen in der Quelle
- Wartungsansätze:
 - Aktualisieren-Kopieren
 - Gesamtaustausch von Dateninhalten
 - Aufwand wächst mit dem Datenvolumen
 - Inkrementelle Kopie
 - nur geänderte Daten aktualisieren
 - Vorkehrungen für Anomalien aus der asynchronen Datenverarbeitung treffen

Update-Anomalien

original relations



materialized view
on
original relations



- Architekturen Data Warehouses vs. Virtuelle Datenintegration
 - Data Warehouses: Datenintegration durch Zusammenführung der Daten in ein einziges physisches "Lager" => Schwerpunkt hier
 - Virtuelle Datenintegration: Daten werden in den Quellen belassen und zum Zeitpunkt der Abfrage abgerufen
- Pro Data Warehouses:
 - Abfragen über das Warehouse stören die Datenquellen nicht
 - Können anspruchsvolle Berechnungen durchführen, einschliesslich Data Mining und Bereinigung
- Contra Data Warehouses:
 - Man muss Zeit aufwenden, um das physische und logische Datenbanklayout zu entwerfen (ist wirklich mühsam!)
 - Die Daten sind in der Regel nicht aktuell (träge oder Offline-Aktualisierung)

EXTRACT-TRANSFER-LOAD (ETL) UND ELT

Extract – Transform – Load (ETL): Der Prozess


- Idee hinter ETL: Integration durch Zusammenführung der Daten in ein einziges physisches Lager (= Data Warehouse)
- Wird auch dort benötigt, wenn nur ein Teil der Daten zusammengeführt wird, während andere in den Quellen «roh» belassen werden (= Data Lakehouse)
- Extrahieren:
 - Selektion eines Ausschnitts der Daten aus den Quellen und Bereitstellung
- Transformieren:
 - Anpassung der Daten an vorgegebene Schema- und Qualitätsanforderungen
- Laden:
 - physisches Einbringen der Daten aus dem Arbeitsbereich (staging area) in das Data Warehouse (einschliesslich eventuell notwendiger Aggregationen)
 - Bei Rohdaten in Data Lakehouses wird ein «Schema-on-Read» gemacht

Extract – Transform – Load (ETL): Der Prozess

- Ein ETL-Prozess kann grundsätzlich durch selbsterstellte Software in einer beliebigen Programmiersprache umgesetzt werden
- Unternehmen nutzen oft bestehende ETL Tools (Standardwerkzeuge) von Drittherstellern
- Die Tools unterstützen oft gängige Systeme und Datei-Ablagen
- Die eigene Entwicklung wird durch vordefinierte Transformationen, Funktionen sowie durch Visualisierung des Datenflusses, der Fehlerbehandlung und des Scheduling unterstützt

Vgl. auch <http://de.wikipedia.org/wiki/ETL-Prozess>

Extract – Transform – Load (ETL): Der Prozess



Transformations-Funktionen (1 von 2)

Eine offene Auflistung. Im Grunde man kann das alles mit SQL lösen :-)!

- String-Operationen: Manipulation von Textdaten, wie z.B. Trimmen, Auffüllen, Gross- und Kleinschreibung ändern, Tausendertrennzeichen löschen.
- Berechnungen in Feldern: Durchführen von arithmetischen oder logischen Operationen an Datenfeldern, um neue Werte abzuleiten, z.B. Datum und Uhrzeit.
- Typumwandlung und Konvertierung: Ändern von Datentypen, z.B. Konvertierung von Strings in Ganzzahlen oder Datumswerte.
- Felder hinzufügen: Hinzufügen neuer Spalten mit Werten (z. B. Konstanten, eindeutige Bezeichner, Zeitstempel).
- Feldaufteilung: Trennen von Feldern, die Listen oder mehrere Werte enthalten, in separate Zeilen oder Spalten.
- Filtern und Löschen von Zeilen: Auswählen von Zeilen, die bestimmten Kriterien entsprechen, und Entfernen derjenigen, die nicht den Kriterien entsprechen (WHERE).
- Umbenennen und Löschen von Feldern in einer Tabelle: Ändern des Schemas eines Datensatzes, z.B. Ändern von Spaltennamen oder Entfernen vorhandener Spalten auf der Grundlage eines Filterausdrucks.
- Gruppieren und Aggregieren: Daten zusammenfassen, indem man nach Feldern gruppiert und Aggregatwerte wie Summe, Durchschnitt, Anzahl, Maximum und Minimum berechnet (GROUP BY).
- Kodierung und Dekodierung: Umwandlung von Datenformaten, z.B. Kodierung kategorischer Variablen in numerische Werte oder umgekehrt (Klassifizierung).
- Deduplizierung: Identifizieren und Entfernen doppelter Datensätze, um die Eindeutigkeit der Daten zu gewährleisten.
- Datenmaskierung und Anonymisierung: Verstecken oder Verschleiern sensibler Informationen zum Schutz der Privatsphäre.

Transformations-Funktionen (2 von 2)


- Anspruchsvollere Funktionen:
 - Tabellen sortieren (SORT): Anordnen von Zeilen auf der Grundlage eines oder mehrerer Felder.
 - Eine Tabelle mit einer anderen verbinden (JOIN): Verbinden von Zeilen aus zwei oder mehr Tabellen auf der Grundlage einer verwandten Spalte zwischen ihnen.
 - Pivotieren (PIVOT) und Unpivotieren (UNPIVOT): Drehen von Daten von Zeilen zu Spalten (oder umgekehrt), um Datensätze für die Analyse umzustrukturieren.
 - Verflachung: Umwandlung hierarchischer Datenstrukturen in ein flaches Format, das für relationale Datenbanken geeignet ist.
 - Zusammenführen/Verbinden: Kombinieren von Daten aus zwei Datensätzen auf der Grundlage eines gemeinsamen Schlüssels, ohne dass eine vollständige Übereinstimmung wie bei Joins erforderlich ist; wird häufig zum Anhängen von Datensätzen verwendet.
 - Nachschlagen/Datenanreicherung: Anreicherung von Daten durch Hinzufügen verwandter Informationen aus Nachschlagetabellen oder externen Datenquellen.
- Erzwingt ein Datenmodell (z.B. für ML):
 - Fehlerbehandlung und Bereinigung: Identifizierung von Fehlern, Inkonsistenzen oder Ausreißern in den Daten und deren Korrektur oder Entfernung.
 - Numerische Normalisierung und Standardisierung: Anpassung der Werte an eine gemeinsame Skala ohne Verzerrung der Unterschiede in den Wertebereichen.
 - Daten-Imputation: Ersetze fehlende oder ungültige Werte durch Näherungswerte wie den Mittelwert, Median oder Modus der Spalte.
 - Umgang mit fehlenden Daten: Fülle fehlende Werte mithilfe von Imputationsmethoden auf oder markiere sie als fehlend, um die Datenintegrität zu wahren.

Extract – Load – Transform (ELT)

- Extract – Transform – Load (ETL)
vs. Extract – Load – Transform (ELT)
- ETL:
 - Daten werden extrahiert/geladen, transformiert/aufgearbeitet und in die Ziel-Senke geladen
 - Die Transformation (Aufarbeitung) erfolgt mit dem Tool in einer Skriptsprache (Kettle: JavaScript) oder einer Programmiersprache (Kettle/Talend: Java)
- ELT:
 - Daten werden extrahiert, in DBMS geladen (Staging DB) und dort aufgearbeitet
 - Aufarbeitung erfolgt in der DBMS von der Staging-DB aus mittels SQL

Reverse ETL

- Reverse ETL ist der Prozess des Kopierens von Daten aus einem zentralen Data Warehouse in operative Systeme.



Quelle: <https://hightouch.io/blog/reverse-etl/>

- Transformationsschritt ist typischerweise performance-kritisch
- ETL – Extrahieren, Transformieren, Laden
 - Ein grundlegender Prozess der Datenanalyse und des Data Warehousing.
 - Kleiner Delay für Analyse
- ELT – Extrahieren, Laden, Transformieren
 - Transformation erfolgt in SQL, kein separates Tools (für Transformation)
 - Transformation wird bis zum Ende des Prozesses verschoben oder bis zur Abfrage verzögert
 - Einfachere Architektur, weniger Speicherplatz (on-demand)
- Mehr dazu nächste VoWo.
 - Mit Zero-ETL und Reverse-ETL

TOOLS FÜR DIE DATENINTEGRATION

Tools für die Datenintegration

- mit Python (und Pandas), Java, .NET, R etc.
 - Jederzeit - aber mühsam zu implementieren und zu pflegen
- mit SQL
 - ELT mit den "Elephanten" DBMS; Challenge sind die (z.T. fehlenden) "Extract"/Reader Tools
 - dbt – data build tool (just the "T" of ETL/ELT) → [1]
 - Mit DBeaver und DuckDB → [3]
- mit Webapps/Plattformen
 - viele kommerzielle Produkte von "ETL-Tools«, AWS Glue, Azure Data Factory
 - Wenige frei verfügbare, typischerweise Formatkonverter wie CSV-zu-was-auch-immer → [1]
- mit GUI-Tools / IDEs und Low Coding (unvollständige Liste; Schwerpunkt Open Source)
 - Kommerziell: Einige! Z.B. MS SQL Server Integration Services (SSIS), Azure Data Factory Studio
 - Apache Hop
 - OpenRefine → [2], Open Data Editor, AirByte, CJ Workbench <https://github.com/CJWorkbench>
- mit Web-Plattformen und Low Coding oder Pipelines (unvollständige Liste)
 - Apache AirFlow: v.a. DataOps und Pipelines
 - Keboola; siehe e.g. [25 Best ETL Tools in 2024 with Detailed Comparison \(softwaretestinghelp.com\)](https://softwaretestinghelp.com/25-Best-ETL-Tools-in-2024-with-Detailed-Comparison/)

[1] siehe nächste Folien; [2] siehe nächste Folien und Übungen; [3] siehe VowWo 08

Tool: OpenRefine

- Desktop-Tool zum Sichten ('Explorieren'), Bereinigen (Aufarbeiten/Säubern), Integrieren und Anreichern von Daten
- Spaltendarstellung/GUI ähnlich Tabellenkalkulation
- Low-coding / No-coding
- Import u.a. der Datenformate CSV, XLS, JSON, XML sowie Datenbanken
- Memory-/RAM-basiert
- Verändert niemals die Quelldaten - ausser man überschreibt sie selber ☹️
- Kolonnen haben keine Datentypen - ausser man weist einen Typ zu
- Java; Open Source (ursprünglich von Google bzw. Metaweb)
- Verbreitet bei Information Scientists, Journalisten, Wikipedianer



Tool OpenRefine (Forts.)

OpenRefine bicycle categories [Permalink](#) [Open...](#) [Export](#) [Help](#)

Facet / Filter Undo / Redo 2 / 2 < 72 rows Extensions: Wikidata

Show as: rows records Show: 5 10 25 50 rows < first < previous 1 of 8 pages next > last >

Using facets and filters

Use facets and filters to select subsets of your data to act on. Choose facet and filter methods from the menus at the top of each data column.


Not sure how to get started?
[Watch these screencasts](#)

All	Record ID	Object Title	Registration Number	Marks	Production Date	Provenance (Production)	Provenance (History)	Categories	Persistent Link
	1. 390466	Shearer's bicycle, 1910 - 1940	2009/9/1	NA	1910 - 1940	Maker: unknown; 1910 - 1940	NA	Bicycles Transport-Land	http://www.powerhc.inn=390466
	2. 389833	'Frog' bicycle lights by Knog, 2004	2008/229/2	NA	2004	Designer: Catalyst Design Group, Melbourne, Victoria; 2004(Maker: Knog Pty Ltd, China; 2008)	NA	Bicycle lamps Transport-Land	http://www.powerhc.inn=389833
	3. 389385	'Gator' bicycle lamp by Knog, 2005 - 2006	2008/229/1	NA	2005 - 2006	Designer: unknown; 2005 - 2006(Maker: unknown; 2008)	NA	Bicycle lamps	http://www.powerhc.inn=389385
	4. 387573	Edworthy tandem monkey bicycle, 1932 - 1936	2008/197/2		1932 - 1936	Maker: Edworthy, Silas; Leichhardt, New South Wales; 1932 - 1936(Maker: Edworthy, Silas; Lidcombe, New South Wales; 1932 - 1936)(Maker: Edworthy, Silas; Guildford, New South Wales; 1932 - 1936)	User: Taronga Zoo, Sydney; 1936 - 1940	Bicycles Transport-Land	http://www.powerhc.inn=387573
	5. 387487	Edworthy monkey bicycle, 1932 - 1936	2008/197/1		1932 - 1936	Maker: Edworthy, Silas; Leichhardt, New South Wales; 1932 - 1936(Maker: Edworthy, Silas; Lidcombe, New South Wales; 1932 - 1936)(Maker: Edworthy, Silas; Guildford, New South Wales; 1932 - 1936)	User: Taronga Zoo, Sydney; 1936 - 1940	Bicycles Photographs Transport-Land Documents	http://www.powerhc.inn=387487
	6. 126859	Bicycle training rollers used by Ron Cazey, 1930 - 1939	2007/53/2	NA	1930 - 1939	Maker: unknown; 1930 - 1939	NA	Bicycle accessories Recreational and Sporting Equipment	http://www.powerhc.inn=126859
	7. 362418	'Blackbird' racing	2007/53/1	Letter 'B' in	1929 - 1939	Maker: unknown; 1929 - 1939	NA	Bicycles Transport-	http://www.powerhc

Tools: Ausgewählte Produkte und Projekte für ETL

- ETL d.h. Daten → **Tool v.a. Extract/Transform** → Datenbank
- Oft Schwerpunkt mehr auf Pipelines oder Machine Learning
- MS SQL Server Integration Services für ETL
 - vgl. oben
- Kommerziell (nicht mehr Open Source ☹️)
 - Pentaho Data Integration mit Kettle/Spoon (Hitachi Vantara): Java, JavaScript
 - Talend Open Studio: Java
- KNIME: ETL und Machine Learning
- Apache Hop: ETL, Fork von Kettle (vgl. folgende Folie und Übungen nächste VoWo)
- Weitere ...
 - Dbt
 - Feature Manipulation Engine (FME), kommerziell
 - GDAL/OGR für Geodaten (Online Tool "GeoConverter OST"), Open Source

- Hop Orchestration Platform
- Desktop-App (Hop GUI) und weitere Tools, Java Open Source



Homepage: <https://hop.apache.org/>

Apache Hop: Ausgewählte Transforms

- Einlesen (Reader) und Schreiben (Writer):
 - Text, CSV, Parquet, DBMS, Cloud (Hinweis: Werden auch als Transforms bezeichnet)
 - Filter Rows: Leitet jede Zeile basierend auf einer benutzerdefinierten Bedingung zu einer wahren oder falschen Ausgabe.
- Zeilen- und Felder-Manipulationen:
 - Select Values: Ändert die Metadaten der Zeile durch Auswahl, RegEx, Umbenennung oder Konvertierung von Feldern.
 - Database Lookup: Führt Abfragen in einer Datenbanktabelle durch und fügt neue Felder hinzu.
- Zeichenketten-Manipulationen:
 - String Operations: Feld-Funktionen wie Kleinschreibung, Ersetzen von Zeichenketten.
 - Set Field Value: Ersetzt den Wert eines Feldes durch den Wert eines anderen Feldes.
 - Value Mapper: Ersetzt Zeichenkettenwerte basierend auf einer definierten Zuordnungstabelle.

Tools für ELT: Import CSV & Excel in Datenbanken



- ELT d.h. **Tools für Extract/Load** der Daten in die
→ Datenbank (wo die Transformation dann mit SQL erfolgt)
- Die Integration von CSV- oder Excel-Dateien in eine Datenbank oder ein Data Warehouse wie PostgreSQL kann mehrere Gründe haben: **Datenanalyse, Datenintegration, zentralisierte Datenverwaltung**
- **Lösung:** Beispiel mit **psql** in einer Shell und einem sauberen CSV:

```
mydb=# COPY persons(Cust_ID, Lastname, Firstname, Date_Birth, ...)  
FROM 'C:\sampledb\address_list.csv'  
DELIMITER ',' CSV HEADER;
```
- **Problem** oben ist, dass zuerst ein (SQL-)Schema erstellt werden muss, das genau zur CSV- oder Excel-Datei passt! Wäre schön, wenn ein Tool die Tipparbeit abnimmt.
- **Lösung:** 1. Online Tools/Platforms (z.B. konbert.com), 2. Data Integration Tools (z.B. Kettle), 3. Import Tools (z.B. CSVKit) oder 4. Python-Programmierung (mit SQLAlchemy/Pandas)
- Tutorial (optionaler Stoff): "Import CSV and Excel Files to PostgreSQL in Simple Ways"
<https://md.coredump.ch/s/ryMceVzMQ#>

- SQL: Aggregationen COUNT(), Selektionen WHERE..., JOINS, etc.
- Tabelle duplizieren / kopieren:


```
CREATE TABLE mytable2 AS  
  SELECT * FROM mytable;
```
- Datentyp einer Spalte col1 und ggf. deren Daten ändern (z.B. TEXT zu INT):

```
ALTER TABLE mytable ALTER COLUMN col1 TYPE INT  
  USING CAST(NULLIF(col1, ' ') AS INT);
```
- Eine Spalte aufteilen ("splitten"):

```
ALTER TABLE mytable  
  ADD COLUMN fname VARCHAR(255),  
  ADD COLUMN lname VARCHAR(255);  
UPDATE mytable  
  SET fname = split_part(fullname, ' ', 1),  
      lname = split_part(fullname, ' ', 2);
```
- Duplikate erkennen und entfernen ("deduplication"): vgl. nächste VoWo

CLI and GUI tool: dbt - "data build tool"

- SQL-Transformation und Flusskontrolle
- Befehlszeilentool - auch eingebettet in AirByte usw.
- Das 'T' von ETL/ELT; Datentransformation durch SQL-Abfragen
- Jinja Template Engine von Python; YAML (XML-ähnlich); Open Source
- Unterstützt Testen, (Code-)Wiederverwendung, Versionierung (im Gegensatz zu GUI-Tools), "SQL-Query-Dependencies"
- Als Desktop-Tool und als Cloud-Service ("dbt cloud")



Zusammenfassung und Diskussion

- Datenintegration (= Informationsintegration), inkl. Funktionen
- Extract-Transfer-Load (ETL) mit Tools und ELT (mit Tools, SQL und DBMS)
- Tools für die Datenintegration: OpenRefine, Apache Hop, dbt, ...

Mehr dazu nächste Woche VoWo 08 (die Letzte in meinem Block)

Übungen heute: Datenaufbereitung mit OpenRefine

Diskussion:

Welche Erfahrungen zur Datenaufbereitung
und Datenintegration haben Sie gemacht?



ANHANG: Quellen

- "Informationsintegration: Architekturen und Methoden zur Integration verteilter und heterogener Datenquellen". Ulf Leser und Felix Naumann (2006), (Deutsch) Taschenbuch. Website (Open Book): <https://www.assets.dpunkt.de/openbooks/information-sintegration.pdf>
- "Principles of Data Integration" by AnHai Doan, Alon Halevy, and Zachary Ives, Morgan Kaufmann, 1st edition (2012), 520 pages. Website (free slides): <https://research.cs.wisc.edu/dibook/> (Schwerpunkt on-the-fly Daten-Integration, vgl. nächste Woche)

